

Implementierungsplan

Reimplementierung des ALPTHERM/Regtherm-Modellansatzes für den Alpenraum auf Basis von ICON-D2 / ICON-EU, Validierung gegen IGC-Streckenflugdaten

1. Zielsetzung und Abgrenzung

Ziel des Projekts ist die Reimplementierung eines Thermikprognose-Modells im Sinne von Liechti & Neiningner (1993) für den Alpenraum. Die Originalphysik des Modells – Volumeneffekt, Area-Height-Distribution, 1D-Energiebilanz pro Region – wird beibehalten, jedoch werden alle 1994 noch empirisch parametrisierten Größen (Strahlungstransmission, Energieaufteilung, Bodentemperatur, großräumige Subsidenz) durch direkte ICON-Diagnostiken ersetzt. Das Modell agiert damit faktisch als topographisch hochaufgelöster Subgrid-Konvektionspostprozessor über ICON.

Nicht Ziel:

- Ein operationelles Produkt auf Augenhöhe mit XC Therm (30 Jahre Tuning fehlen).
- Reverse Engineering der XC-Therm-internen Parameter.
- Eine eigene NWP-Komponente – ICON liefert die meteorologische Basis.

2. Systemarchitektur

Das Gesamtsystem zerfällt in fünf locker gekoppelte Komponenten, die je für sich entwickelt und getestet werden können:

Komponente	Aufgabe	Input	Output
A. Region & AHD	Geometrie pro Region	Copernicus DEM 30m	Polygone + AHD-Profile
B. ICON-Pipeline	NWP-Daten ziehen & aufbereiten	DWD Open Data	Regionsprofile (NetCDF)
C. Modellkern	1D-Konvektion pro Region	Profile + AHD	$v(z,t)$, Basis, Top
D. IGC-Pipeline	Flugdaten beschaffen & auswerten	WeGlide API / OLC	Kreisflug-Statistik pro Region/Bin
E. Validierung & Tuning	Bias-Analyse, Parameter-Fit	C + D + ICON-Diagnostik	Kalibrierte Parameter

Komponenten A und B sind reine Daten-Pipelines und unabhängig voneinander lauffähig. C hängt von A und B ab. D ist unabhängig. E integriert C und D mit einer Cross-Reference auf ICON-Diagnostiken aus B (HBAS_SC, HTOP_DC) für die Basishöhen-Validierung.

3. Komponente A — Regionsgeometrie und AHD

Liechti's Schlüsselparameter ist die Area-Height-Distribution: pro 100m-Höhen-schicht das atmosphärische Restvolumen $V_a(z)$ und die horizontal projizierte Geländeoberfläche $S_G(z)$ (Heizfläche). Beide werden aus einem DEM deterministisch berechnet.

3.1 Regionsdefinition

Es existiert **keine publizierte Spezifikation**, wie Liechti die ALPTHERM/Regtherm-Regionen konkret geschnitten hat — die Abgrenzung wurde vermutlich manuell-meteorologisch nach jahrzehntelanger Erfahrung vorgenommen. Das REGTHERM-2001-Paper beschreibt nur die Kopplung zwischen Regionen, nicht deren Definition. Die Regionsdefinition wird daher selbst entwickelt, gestützt auf drei Referenzstränge: hydrologische Einzugsgebiete, datengetriebene Regionalisierung und Talwind-Meteorologie.

Eckwerte:

- Ziel: ca. 20–30 Regionen für den gesamten Alpenraum (vergleichbar Granularität alte Regtherm-Einteilung).
- Regionsgröße: 500–1500 km² im Gebirge (Liechti's Empfehlung), Untergrenze durch ICON-Auflösung gesetzt (siehe Level-Wahl).
- Speicherung: GeoJSON-Polygone in EPSG:4326, plus Repräsentationspunkt (Centroid).

HydroBASINS-Level-Wahl:

HydroBASINS-Level haben keine feste Fläche, sondern eine Größenverteilung (Pfaffstetter-Subdivision: jeder Knoten teilt topologisch in 9). Relevanter Bereich:

Level	Mittlere Fläche (grob)	Einordnung
7	~1.500–5.000 km ²	Obergrenze, eher zu grob (Gebirgsgruppen)
8	~500–1.500 km ²	Liechti's Zielgröße — Haupttäler (BASIS)
9	~150–500 km ²	XC-Therm-Richtung — Seitentäler (Verfeinerung)
10	~50–150 km ²	Einzelne Talkessel — meist zu fein
11–12	~13–130 km ²	Zu kleinteilig für 1D-Annahme

Trend Alptherm → XC Therm: Das alte Alptherm/Regtherm nutzte ~31 österreichische Regionen (≈ Level 7–8); XC Therm rechnet heute >1300 europäische Regionen (≈ Level 9–10). Diese Verkleinerung wurde aber erst durch bessere Trägermodelle sinnvoll — die 1D-Annahme gilt nur, solange die Region intern halbwegs homogen konvektiv ist.

ICON-Auflösung als physikalische Untergrenze: Wird feiner geschnitten als die effektive Input-Auflösung, gewinnt man keine Information — man verteilt denselben Gitterpunkt auf mehrere Regionen (Scheingenauigkeit). ICON-D2 (2,2 km): Untergrenze ~100–250 km² für 20–50 Gitterpunkte je Region → spricht für Level 9. ICON-EU (7 km): 100 km² wären nur ~2 Punkte → für EU-gestützte Tage auf Level 8 bleiben bzw. Level-9-Regionen für die EU-Statistik wieder aggregieren.

Empfehlung — Level 8 als Anker, Level 9 als Verfeinerungsreservoir: Stufe 1 startet auf Level 8 (Liechti-Granularität, robust für beide ICON-Modelle). Stufe 3 verfeinert selektiv auf Level 9, aber nur wo die Varianzanalyse es rechtfertigt. Da HydroBASINS hierarchisch genestet ist, ist das Splitten trivial: Eine Level-8-Region zerfällt durch Anhängen einer Pfaffstetter-Ziffer exakt in ihre Level-9-Kinder — ein reines Dissolve/Un-dissolve über die PFAF_ID, kein eigener Schnittalgorithmus nötig. Im Alpenvorland kehrt sich die Logik um: dort

eher gröber (Level 7-8), da die Thermik großräumig homogen ist und Level 9 künstlich viele fast identische Regionen erzeugen würde.

Dreistufiges Verfahren:

Stufe 1 — Geometrisches Gerüst (Einzugsgebiete). Talwindssysteme folgen Einzugsgebieten; die natürlichste Regionsgrenze ist daher die topographische Wasserscheide. Basis: HydroBASINS (Pfafstetter-codiert, hierarchisch) bzw. EU-Hydro (Copernicus, feiner für Europa), zugeschnitten auf die Zielgröße. Liefert physikalisch motivierte, räumlich zusammenhängende Startregionen ohne Tuning.

Stufe 2 — Manuelle meteorologische Korrektur. Hauptkamm-Teilung erzwingen (Nord-/Zentral-/Südalpen trennen). Keine Region darf über den Alpenhauptkamm schneiden, da Nord- und Südseite gegenläufige thermische Tagesgänge haben. Talverzweigungen als natürliche Grenzen. Dies ist die einzige Stufe mit bewusst eingebrachtem meteorologischem Erfahrungswissen (statt rein datengetriebenem Schnitt).

Stufe 3 — Datengetriebene Verfeinerung. Regionen mit dauerhaft hoher regionsinterner Varianz (HBAS_SC, Windrichtung) werden identifiziert und entlang topographischer Strukturen gesplittet (vgl. Abschnitt 7.3). Werkzeug: räumliche Clustering-Verfahren mit Kontiguitäts-Constraint (PySAL/spopt: max_p_regions, skater, region_k_means). Attribute: mittlere Geländehöhe, Exposition, saisonale ICON-Statistik (HBAS_SC, Wind, Wärmeströme). Normale Cluster-Verfahren (k-means) sind ungeeignet, da sie keine zusammenhängenden Gebiete garantieren.

Historische Daten für Stufe 3 — wichtige Entkopplung: Der DWD Open Data Server hält nur ein rollierendes 2-Tage-Fenster vor; ein Langzeitarchiv der GRIB2-Läufe existiert öffentlich nicht. Stufe 3 benötigt jedoch *keine* echten Vorhersagen, sondern nur die räumliche *Klimatologie* der Streuungsmuster — eine statistische Eigenschaft der Topographie-Wetter-Wechselwirkung. Stufe 3 wird daher von der operationellen Pipeline (Komp. B) entkoppelt und auf einen bereits existierenden Archiv-/Reanalyse-Datensatz gestützt (siehe Anhang 12.4). Damit ist kein monatelanges Vorab-Sammeln nötig — Stufe 3 ist sofort startbar.

Physikalische Leitplanken (Whiteman; Zardi & Whiteman): Eine Region umfasst ein zusammenhängendes Talwindsystem; Becken und Täler werden getrennt behandelt (beckenspezifischer Volumeneffekt); nicht über Hauptkämme schneiden. Damit produziert das Clustering keine physikalisch unsinnigen Regionen.

3.1.1 Sonderfall Alpenrand — Quer-Segmentierung langer Täler

HydroBASINS-Einzugsgebiete am Alpenrand (z.B. Iller, Lech, Salzach) erstrecken sich vom Hauptkamm bis tief ins Vorland. Als *eine* Region behandelt würden sie Hochgebirgsthermik (3000 m, steile Heizflächen, später Onset, hohe Basis) mit Flachland-Konvektion (500–700 m, früher Onset, feuchtere Böden) vermischen — meteorologisch unzulässig. Das Einzugsgebiet ist die richtige Logik *längs* der Talachse (Talwind), aber die falsche *quer* dazu (thermische Homogenität). Lösung: ein zusätzlicher Schnitt nach Geländecharakter.

- **Relief-/Höhen-Segmentierung:** Lange Einzugsgebiete in Hochgebirgs-, Voralpen- und Flachlandsegment zerlegen. Indikator: Reliefenergie (max–min Höhe im gleitenden Fenster) plus mittlere Höhe. Trennt "echtes Gebirge" zuverlässig von Hügelland.
- **Alpenkonvention-Perimeter als physiographische Maske:** Die etablierte, frei verfügbare Alpenraum-Abgrenzung (alternativ Alpine Space) schneidet genau dort, wo das physikalische Regime wechselt — wissenschaftlich konsenterte Grenze statt selbst gewählter.
- **Vorland als eigene Regionsklasse:** Das Alpenvorland wird mit-vorhergesagt, aber mit anderem Modellverhalten (siehe Kasten).

Alpenvorland-Modellklasse: Im Flachland ist die Thermik annähernd horizontal homogen — Liechtis AHD-Volumeneffekt ist dort nicht gültig. Vorland-Regionen werden daher als vereinfachtes Mixed-Layer-Modell auf Basis derselben ICON-Wärmeströme (ASHFL_S, ALHFL_S) geführt, ohne Talvolumen-Logik. Das ist ehrlicher als ein als "Tal" verkleidetes Flachland und liefert trotzdem Onset, CBL-Höhe und Steigwerte. Die Regionsgeometrie im Vorland kann gröber sein (geringere topographische Heterogenität).

Wichtig — Talwind-Konnektivität bewahren: Ein Quer-Schnitt zertrennt ein zusammenhängendes Talwindssystem. Der Talwind transportiert Feuchte und Luftmasse vom Vorland ins Gebirge (genau der Regtherm-Kopplungsmechanismus, siehe 5.5). Die Segmente werden daher geometrisch getrennt, aber in der Kopplungsstufe als vertikal benachbarte, gekoppelte Regionen wieder verbunden. Jeder Schnitt entspricht so einer physikalischen Grenze: Wasserscheide (längs), Alpenrand (Regimewechsel), Reliefstufe (Gültigkeit des Volumeneffekts).

3.2 AHD-Berechnung

Input: Copernicus DEM GLO-30 (~30m). Pro Region:

- Höhenklassen von Talgrund bis höchste Erhebung in 100m-Schritten.
- $S_G(z)$ = Anteil der DEM-Pixel in der jeweiligen Höhenklasse, multipliziert mit Regionsfläche.
- $V_a(z)$ = Differenz zwischen Maximalvolumen einer 100m-Schicht und dem von Topographie eingenommenen Volumen.
- Ergänzend: mittlere Hangneigung und Exposition pro Höhenklasse — Erweiterungs-Hook für Richters Kritik an steilen Heizflächen.

Zusätzlich — Schwellenhöhen des Regionsgraphen (für die Kopplung, 5.5):

Neben den AHD-Profilen je Region wird pro Regionsnachbarschaft (Kante des Nachbarschaftsgraphen) die effektive Schwellenhöhe bestimmt: die niedrigste Stelle im DEM entlang der gemeinsamen Polygongrenze, relativ zu den Talböden beider Regionen. Daraus leitet sich der Grenztyp (offener Übergang / Talverzweigung / Pass / Hauptkamm) und später der Durchlässigkeitsfaktor ab. Dies wird einmalig berechnet und als Kanten-Attribut gespeichert — die Datengrundlage für die differenzierte Kopplung in Phase 2.

3.3 Aufwand

Geschätzt 1-2 Wochen. Stack: Python mit *rasterio*, *geopandas*, *xarray*. Output ist ein Pickle/NetCDF pro Region mit AHD-Profilen, wird einmal berechnet und danach statisch genutzt.

4. Komponente B — ICON-Datenpipeline

Bezugsquelle: DWD Open Data unter <https://opendata.dwd.de/weather/nwp/>. ICON-D2 (2.2 km) für Tag 0-2, ICON-EU (7 km) für Tag 2-5. Initialisierungen alle 3h, Forecast-Schritte stündlich.

4.1 Variablenliste

Kategorie	Variable	Verwendung im Modell
Initialprofile	T, QV, P, U, V, W, HHL	Vertikale T/q-Profil, Wind, großräumige Subsidenz
	W_SO (4 Layer)	Bodenfeuchte → ersetzt 'Evap=const'
Strahlung (akk.)	ASOB_S, ATHB_S	Netto-Strahlungsbilanz statt Liechti-Formeln
	ASWDIR_S, ASWDIFD_S	Direkte/diffuse Komponenten optional
Wärmeströme	ASHFL_S, ALHFL_S	Sensibler/latenter Wärmestrom direkt
Bewölkung	CLCT_MOD, CLCH, CLCM, CLCL	Bewölkungseinfluss bereits in Strahlung
Bodennahe Größen	T_2M, TD_2M, T_G, RELHUM_2M	Bodentemperatur, Feuchte, T_S statt $\delta \cdot P$
Konvektions-Diag .	HBAS_SC, HTOP_SC	Cu-Basis (Tuning-Target für Cu-Tage)
	HBAS_CON, HTOP_CON	Hochreichende Konv. → Ausschlusskriterium
	HTOP_DC	Trockenkonvektion (Blue-Day Validierung)
	CAPE_ML, CIN_ML, LCL_ML, HZEROCL	Zusätzliche Diagnostik
Grenzschicht	HPBL, TKE	Cross-Check für eigenes CBL
Statisch	HSURF, SOILTYP, PLCOV, ROOTDP	Bodencharakteristik pro Region

4.2 Pipeline-Schritte

- Download via HTTP, GRIB2-Format, Filter auf benötigte Variablen (reduziert Volumen drastisch — voller Lauf wäre > 100 GB/Tag).
- Räumliche Extraktion: **alle** Gitterpunkte innerhalb des Region-Polygons (nicht nur ein Referenzpunkt — siehe 4.3).
- Vertikale Interpolation auf einheitliches Höhengitter (100m, passend zur AHD-Schichtung).
- Akkumulierte Größen (Strahlung, Wärmeströme) auf Stundenraten differenzieren.
- Output: NetCDF pro Tag und Region mit aggregierten Profilen, diagnostischen Werten und Streuungsmaßen als Zeitreihe.

4.3 Regionale Aggregation statt Einzelpunkt

Ein einzelner Referenzpunkt repräsentiert die Region schlecht — gerade bei räumlich fleckigen, nichtlinearen Feldern wie Bewölkung und Konvektions-diagnostik. Stattdessen wird über alle Gitterpunkte im Polygon aggregiert, wobei **nicht nur die zentrale Tendenz, sondern auch die Streuung** behalten wird. Die Aggregationsmethode ist je nach Variablentyp unterschiedlich:

Variable	Aggregat	Zusätzlich behalten	Begründung
Strahlung / Wärmeströme (ASOB_S, ASHFL_S, ALHFL_S)	Flächenmittel, höhenstratifiziert	P(z)-Profil je Höhenklasse	Extensive Flüsse; Mittel ist physikalisch korrekt; höhenaufgelöst direkt in AHD einspeisbar
Bewölkung (CLCT_MOD)	Median	Q25, Q75	Robust gegen einzelne überschießende Zellen
Konvektion (HBAS_SC, HTOP_DC)	Median der gültigen Punkte	Anteil gültiger Punkte	Gültigkeitsanteil = direkter Auslöse-/Bedeckungs-indikator, den ein Einzelpunkt nicht liefern kann
Profile (T(z), q(z))	nach Höhenband getrennt mitteln	Tal- vs. Hochlagenprofil	Mitteln über versch. HSURF verschmiert Inversionen — diese sind aber für die Obergrenze entscheidend
Wind (U, V)	Vektormittel	Richtungs- & Geschw.-Varianz	Hohe Varianz = mögliche Konvergenz = potenziell exzellente Thermik; Streuung ist hier das Signal

Schlüsselgröße "Anteil aktiver Konvektion": Der Prozentsatz der Gitterpunkte mit gültigem HBAS_SC ist ein Bedeckungs- und Auslöseindikator, der prinzipiell nicht aus einem Einzelpunkt ableitbar ist, aber direkt mit der Flugbarkeit korreliert. Wird als eigenständiges Feature mitgeführt.

4.4 Auflösungsabhängigkeit der Statistik

- **ICON-D2 (2.2 km):** ca. 200 Gitterpunkte in einer 1000-km²-Region — ausreichend für robuste Perzentile und Varianzmaße.
- **ICON-EU (7 km):** nur ca. 20 Punkte — Statistik dünn, daher auf Median + Gültigkeitsanteil beschränken, keine feinen Perzentile.

4.5 Eigenes Archiv ab Projektbeginn aufbauen

Da der DWD Open Data Server nur ein 2-Tage-Fenster vorhält, sollte ab Tag 1 des Projekts ein eigener Cron-Job die benötigten ~15 Variablen für die Alpen-Bounding-Box täglich abgreifen und persistent speichern. Bis Komponente C steht und die echte Validierung beginnt, ist so bereits eine eigene Saison beisammen — ohne Abhängigkeit von Drittarchiven. Für die Historie davor (Stufe-3-Klimatologie und Rück-Validierung) dienen die externen Archive aus Anhang 12.4.

4.6 Operationeller Lauf-Rhythmus

ICON-D2 (2.2 km) liefert 8 Läufe/Tag (00, 03, 06, 09, 12, 15, 18, 21 UTC), je +48 h, 1-h-Schritt. ICON-EU (7 km) liefert +120 h aus den Läufen 00/06/12/18 UTC und +30 h aus 03/09/15/21 UTC. ICON-D2-RUC (seit 2024, stündlich, nur +14 h) ist für Tagesthermik zu kurzfristig. Segelflug-relevant ist die Konvektion ca. 09–18 Uhr Lokalzeit (07–16 UTC im Sommer).

Nicht alle 8 D2-Läufe werden verarbeitet — aufeinanderfolgende Läufe unterscheiden sich oft nur marginal. Empfohlen ist ein gestaffelter Rhythmus mit 3–4 Modellrechnungen des ALPTHERM-Kerns pro Tag:

Zweck	Lauf	Lokalzeit (Sommer)	Liefert
Vorausblick Tag 2-5	ICON-EU 00 UTC	~04-05 Uhr fertig	Tagesauswahl, Reiseentscheidung
Haupt-Tagesprognose (Anker)	ICON-D2 03 UTC	~07 Uhr fertig	Verbindliche Prognose für heute
Vormittags-Update	ICON-D2 06 UTC	~10 Uhr fertig	Korrektur vor dem Start
Optional Mittags-Update	ICON-D2 09 UTC	~13 Uhr fertig	Anpassung Nachmittagsthermik

Verfügbarkeitslatenz:

Die Open-Data-Bereitstellung hinkt der Initialisierung um ca. 2,5-3 h hinterher. Der 03-UTC-D2-Lauf ist also gegen 05:30-06:00 UTC abrufbar, fertig prozessiert ca. 06:30 UTC (08:30 Lokalzeit) — passend für die Morgenprognose. Wer früher dran sein will, nutzt den 00-UTC-Lauf (älter initialisiert, aber früher da).

Konsistenz der Prognose (UX):

Mehrfaches Neurechnen lässt die Prognose zwischen Läufen springen (verwirrend für Nutzer: "eben 2200 m Basis, jetzt 1900"). Zwei Gegenmaßnahmen, früh festzulegen: (a) den Anker-Lauf (03 UTC) als "offizielle Tagesprognose" fixieren und spätere Läufe nur als "Update" kennzeichnen, oder (b) leichte zeitliche Glättung über die letzten 2 Läufe.

4.7 Werkzeuge

eccodes / *cfrib* für GRIB2-Decoding, *xarray* für die Datenstruktur, *requests* oder *aiohttp* für parallele Downloads. Speicherplatz pro Saison (April-September) pro Region grob geschätzt ca. 200 MB.

5. Komponente C — Modellkern (1D-Konvektion)

Liechtis Physik bleibt erhalten, aber stark aufgeräumt. Folgende Größen kommen ab sofort aus ICON und werden **nicht mehr** intern parametrisiert:

5.1 Was aus ICON kommt

- P (Gesamtstrahlungsbilanz) = $ASOB_S + ATHB_S$
- $P_{sens} = ASHFL_S$, $P_{lat} = ALHFL_S$ (Vorzeichenkonvention beachten)
- $T_S = T_G$ (kein $\delta \cdot P$ mehr)
- Großräumige Subsidenz = W aus ICON
- Initial- und Boundary-Profil T , q aus ICON-Modellleveln

5.2 Was im Modell verbleibt (Liechti-Kern)

Pro Zeitschritt Δt (vorgeschlagen 2 min, wie Original):

- Sensible Wärme pro Schicht: $H_{sens} = P_{sens} \cdot \Delta t \cdot S_G(z)$
- ΔT -Bestimmung mit Zwei-Regime-Logik (linear bzw. gesättigt bei ΔT_0)
- Paketmasse: $m_p = H_{sens} / (c_p \cdot \Delta T)$
- Auftriebsenergie schichtweise gegen aktuelles $T(z)$ -Profil
- Vertikalgeschwindigkeit $v = (2E/m)^{0.5}$
- Entrainment/Detrainment mit Koeffizienten E_{n0} , D_{c0}
- Windreduktion $f_{kin} = 1 - r \cdot u^2$
- Kondensation oberhalb LCL $\rightarrow$ Cu-Bildung; Modell-Wolkenbase ableitbar
- Profilfortschreibung durch Massentransport & Subsidenz aus ICON-W

5.3 Outputstruktur

- $v(z,t)$ pro Region — 100m-Auflösung, 30min-Bins (kompatibel zu IGC-Binning)
- Trockene CBL-Höhe (Modell-HTOP_DC-Äquivalent)
- Cu-Basis und -Top (falls feuchte Konvektion)
- Flugzeugsteigen via Polare (Standard-Klasse als Default)

5.4 Aufwand

Geschätzt 4-6 Wochen für eine saubere, vektorisierte numpy-Implementierung mit Tests gegen Liechtis Beispielfall (Subsidenz-Sensitivität, Fig. 4 im Originalpaper).

5.5 Regionale Kopplung (Regtherm-Mechanismus)

Das Original-ALP THERM (1993) behandelt jede Region isoliert. Liechti (2002) erweiterte es zu Regtherm durch **horizontale Kopplung benachbarter Regionen**, um Sekundärzirkulationen — Talwindsysteme und Seebrisen — zu erfassen. Diese Kopplung ist aus zwei Gründen relevant:

- **Feuchte-/Massentransport:** Talwinde führen feuchtere Vorlandluft ins Gebirge — beeinflusst Wolkenbasis und Onset.
- **Verbindung quer-segmentierter Täler (siehe 3.1.1):** Wenn ein Alpenrand-Tal in Hochgebirgs- und Vorlandsegment getrennt wurde, stellt die Kopplung den physikalischen Zusammenhang wieder her.

Modellierte Physik — thermisch getriebene Sekundärzirkulation:

Regtherm löst nicht die 3D-Strömung auf, sondern parametrisiert einen horizontalen Austauschterm zwischen den vorhandenen 1D-Regionssäulen. Der abgebildete Kreislauf:

- **1. Differentielle Erwärmung:** Benachbarte Regionen heizen sich unterschiedlich auf (Tal stärker als Ebene durch Volumeneffekt; Südseite stärker als Nordseite).
- **2. Horizontaler Druckgradient:** Die wärmere Region hat geringere Dichte → in der Höhe relativer Hochdruck, am Boden relativer Tiefdruck.
- **3. Bodennahe Ausgleichsströmung:** Luft fließt bodennah von der kühleren zur wärmeren Region — das ist der Talwind / die Seebrise.
- **4. Massenkontinuität:** Der einströmenden Bodenluft entspricht ein Gegenstrom in der Höhe, gespeist von der Konvektion der wärmeren Region — die Zirkulationszelle schließt sich.
- **5. Rückkopplung auf die Thermik:** Die einströmende Luft bringt Feuchte und Masse: niedrigere Wolkenbasis (ggf. Überentwicklung), begrenzte CBL-Höhe, "Deckelung" der Nachmittagsthermik bei einsetzendem Talwind.

Zentral — der thermische Wind ist OUTPUT, nicht Input: Die Talwind-/Seebrisen-Komponente wird vom Modell aus der differentiellen Erwärmung der gekoppelten CBLs *selbst erzeugt*. Genau das ist der Sinn der Kopplung. Der ICON-Bodenwind (10 m) darf **nicht** als Input der Kopplung dienen — sonst wäre die Zirkulation doppelt enthalten (einmal in ICONs Wind, einmal aus der Kopplung) und das Modell redundant. Der ICON-Bodenwind ist stattdessen eine *Validierungsgröße*: Stimmt der berechnete Talwind plausibel mit ICONs Bodenwindfeld überein?

Tatsächliche Inputs der Kopplung:

Input	Quelle	Rolle
CBL-Temperaturprofil je Region	Modellkern (C) selbst	Treibt Dichte-/Druckunterschied
Geometr. Nachbarschaft + Distanz	Regionsdefinition (A)	Gradient = $\Delta p / \Delta x$
Höhendifferenz der Regionsböden	DEM (A)	Geopotential-Bezug
Synoptischer Wind (U/V auf Levels)	ICON	Modulator: Zusammenbruch bei Starkwind, Advektion
Feuchteprofil je Region	Modellkern + ICON-Init.	Was der Talwind an Feuchte transportiert

Der synoptische Wind aus ICON ist also sehr wohl ein Input — aber als *Modulator* (Steigwert-Reduktion via f_{kin} , Zusammenbruch der Zirkulation bei Starkwind, Luftmassen-Advektion), nicht als Treiber der Sekundärzirkulation selbst.

Grenztypologie — eigene Weiterentwicklung über publiziertes Regtherm hinaus:

Das publizierte Regtherm behandelt Regionsnachbarschaften pauschal. Tatsächlich ist eine Kopplung über einen 2500-m-Hauptkamm physikalisch etwas völlig anderes als der offene Übergang Vorland→Voralpental. Entscheidend ist, wie leicht Luft zwischen den Säulen ausgetauscht werden kann — eine Eigenschaft der *Grenzttopographie*, nicht des bloßen Polygonrands. Vier Grenztypen decken die Alpen-Realität ab:

Typ	Grenze	Kopplung	Charakter
1	Offener Übergang (Vorland ↔ Voralpental)	stark, bidirektional	Haupt-Feuchteeintrag, klassischer Talwind-Einlass
2	Talverzweigung (Tal ↔ Seitental)	mittel, richtungsabh.	kanalisiert durch Talgeometrie
3	Pass / Sattel	schwach-mittel, schwellwertbehaftet	Überströmen erst wenn CBL die Passhöhe erreicht
4	Hauptkamm (hohe Wasserscheide)	≈ null / entkoppelt	bodennaher Austausch praktisch null

Verbindender Parameter — effektive Schwellenhöhe: Die vier Typen lassen sich über eine kontinuierliche, DEM-ableitbare Größe parametrisieren statt über diskrete Kategorien: die Höhe des niedrigsten Übergangs entlang der gemeinsamen Grenze relativ zu den Talböden (Sattelhöhe). Offener Übergang: Schwelle ≈ Talboden → max. Kopplung. Pass: moderat darüber → schwellwertbehaftet. Hauptkamm: weit darüber → keine Kopplung. Berechnung: niedrigste Stelle entlang der gemeinsamen Polygongrenze im DEM, verglichen mit den Talbodenhöhen beider Regionen.

Durchlässigkeitsfaktor (Vorschlag, zu kalibrieren):

Der Austauschterm aus der Inputs-Tabelle wird um einen Durchlässigkeitsfaktor erweitert, der den Druckgradienten moduliert:

$$\text{Austauschfluss} \approx (\text{Druckgradient } \Delta p / \Delta x) \times D(z_{\text{CBL}} - z_{\text{Schwelle}})$$

Die Durchlässigkeit D ist eine Funktion der Differenz aus CBL-Höhe und Schwellenhöhe: null unterhalb der Schwelle (Täler entkoppelt), ansteigend darüber. Eine plausible funktionale Form ist ein weicher Schwellwert, z.B. $D = \max(0, (z_{\text{CBL}} - z_{\text{Schwelle}}) / z_{\text{skala}})$, begrenzt auf $[0,1]$, mit einer Übergangsskala z_{skala} (Größenordnung einige hundert Meter). Damit ergibt sich automatisch das richtige Verhalten: Hauptkämme koppeln nie (Schwelle zu hoch), offene Übergänge immer (Schwelle ≈ Talboden), Pässe ab dem Zeitpunkt am Tag, an dem die Thermik die Passhöhe durchbricht. **z_{skala} und die genaue Form sind eigene Annahmen und gegen IGC-Daten zu kalibrieren** — sie gehen über das publizierte Regtherm hinaus.

Gerichtete, tageszeitabhängige Kopplung am Vorland-Übergang (eigene Erweiterung):

Beim Typ-1-Übergang ist die Kopplung *asymmetrisch*: Tagsüber dominiert der Fluss Vorland→Gebirge (Talwind bergeinwärts, Feuchteeintrag — thermikrelevant); der nächtliche Rückfluss (Bergwind talauswärts) ist für die Thermik kaum relevant. Die Kopplung sollte daher kein symmetrischer Diffusionsterm sein, sondern ein *gerichteter, tageszeitabhängiger* Term, der den dominanten Tagfluss abbildet. Auch dies ist eine eigene Erweiterung gegenüber dem publizierten Regtherm und zu kalibrieren.

Phasenplan:

Die Kopplung ist *nicht* Teil der ersten Modellversion. Phase 1 liefert isolierte Regionen (Original-ALPTHERM-Verhalten) — für die meisten Strahlungstage bereits brauchbar. Phase 2 fügt den Austauschterm hinzu, inklusive der Grenztypologie: pro Regionsnachbarschaft wird einmalig die Schwellenhöhe aus dem DEM bestimmt (Komp. A liefert das als Kanten-Attribut des Regionsgraphen), dann der Durchlässigkeitsfaktor und die gerichtete Kopplung kalibriert. Die genaue Parametrisierung (Massenfluss je Temperaturdifferenz, Übergangsskala z_{skala} , Schwellwert für den Zusammenbruch bei synoptischem Starkwind) ist bei Liechti **nicht publiziert** — das REGTHERM-2001-Paper beschreibt das Konzept, nicht die Konstanten. Dies ist der schwierigste zu rekonstruierende Teil und wird gegen IGC-Daten und ICONs Bodenwindfeld kalibriert.

6. Komponente D — IGC-Validierungspipeline

Primärquelle WeGlide (offene REST-API), sekundär OLC bei Lücken.

6.1 Datenbeschaffung

- WeGlide-API: Flüge nach Datum und geographischem Filter (Alpen-Bbox)
- IGC-Files herunterladen, lokal cachen
- Metadaten extrahieren: Pilot, Flugzeugklasse, Polare-Hinweis, Startplatz

6.2 IGC-Aufbereitung (nach Richter 2011)

- Kreisflug-Detektion: Krümmungsparameter über gleitendes 2-min-Fenster
- Verlagerungsvektor als Drift-Korrektur
- Minimale Dauer 2 min, kontinuierliche Drehrichtung
- Ausschluss: F-Schlepp-Phase, Motorsegler-Steigen erkennen (plötzliche v -Sprünge), Hangwind/Welle filtern
- Pro Kreisflug-Phase: mittlere Vertikalgeschwindigkeit, mittlere Höhe, Zeitstempel

6.3 Zuordnung zu Region und Zeit-Bin

- Räumlich: Kreisflug-Centroid in Region-Polygon (NICHT Startplatz!)
- Zeitlich: 30-min-Bins, lokale Sommerzeit beachten
- Aggregation pro (Region, Tag, 30min-Bin): N Kreise, Median & Q90 v_{climb} , max. Höhe

6.4 Aufwand

Geschätzt 3–4 Wochen. Kritischer Punkt: Robustheit der Kreisflug-Detektion. Richters Implementierung als Referenz; in modernem Python mit *pyigc* oder eigener Parser.

6.5 WeGlide API-Zugang und ToS-Konformität

WeGlide stellt eine öffentliche Lese-API bereit (*api.weglide.org*, Swagger-Doku unter */docs*) und ermutigt ausdrücklich zur Nutzung. Lesezugriff auf alle öffentlichen Daten (Flüge, Flugzeuge, Flugplätze, Nutzer, Clubs) ist ohne Authentifizierung möglich. OAuth ist nur für schreibenden Zugriff nötig und hier **nicht** erforderlich. Es gibt keine veröffentlichten harten Rate Limits; die ToS untersagen qualitativ nur "exzessive oder missbräuchliche" Nutzung.

Kritische Punkte:

- **Firewall / nicht-residentielle IPs:** Zugriffe von Server-IPs (Cloud, Rechenzentrum) werden zur Spam-Abwehr oft blockiert — *nicht* wegen Rate Limits, sondern wegen der IP-Herkunft. Lösung: API-Key direkt bei WeGlide anfragen.
- **API nicht final:** Endpunkte können sich ändern; Versionierung ist geplant. Pipeline gegen Änderungen robust halten.
- **Attribution:** Bei Veröffentlichung von Ergebnissen ist die von WeGlide geforderte Quellenangabe Pflicht.
- **IGC-Qualität garantiert:** Logging-Lücken dürfen 120 s nicht überschreiten — fein genug für die Kreisflug-Detektion.

ToS-konforme Zugriffsstrategie:

- **API-Key proaktiv anfragen** mit Projektbeschreibung (wissenschaftliche Modellvalidierung) — löst Firewall-Problem und signalisiert guten Willen.

- **Aggressives lokales Caching:** jedes IGC-File nur einmal ziehen, persistent speichern. Historische Saison wird genau einmal geladen — größter Hebel gegen "exzessive Nutzung".
- **Höfliches Crawling:** 1-2 s Verzögerung zwischen Calls, sequenziell statt massiv parallel. Bei einmaliger historischer Abfrage ist Tempo irrelevant.
- **Inkrementelles Update** im laufenden Betrieb: nur neue Flüge seit letztem Abruf holen.
- **Vorhandener Python-Client** (PyPI: WeGlide-Python-Client, aus OpenAPI generiert) spart Endpoint-Mapping, muss aber bei API-Änderungen neu generiert werden.

7. Komponente E — Validierung und Parametertuning

7.1 Verbleibende Tuning-Parameter

Parameter	Bedeutung	Tuning-Target	Liechti-Wert
ΔT_0	Max. T-Diff. Paket/Umgebung pro Schicht	IGC-Steigwerte (Median & Q90)	0.5 K
P_0	Sättigungsschwelle Wärmestrom	Tagesgang-Form (Onset, Ende)	—
E_{n0}	Entrainment-Koeffizient	Höhenabhängigkeit $v(z)$, Wolkenbasis	0.02 s/m
D_{c0}	Detrainment-Koeffizient	Form der oberen CBL	0.08 s/m
r	Windreduktion	v vs. Windgeschwindigkeit	geraten
Bart-Skalierung	mean lift → best lift	Verteilung gegen IGC-Q90	implizit

7.2 Drei Validierungs-Layer

Die Tageklassifikation erfolgt automatisch aus ICON-Diagnostik:

Tagestyp	Erkannt durch	Validierungs-Target	Was wird kalibriert
Cu-Tag	HBAS_SC gültig	HBAS_SC + IGC-Maxhöhen	Feuchteprozess, LCL-Verhalten
Blue Day	HBAS_SC fehlt, HTOP_DC niedrig	HTOP_DC + IGC-Maxhöhen	CBL-Energiebilanz, Entrainment
Gewittertag	HBAS_CON gesetzt	Tag ausschließen	—

Wichtig zur Vermeidung von Zirkularität: Die Basishöhe wird primär gegen die ICON-Diagnostiken (HBAS_SC, HTOP_DC) getunt, da diese flächendeckend und lückenlos verfügbar sind. Die IGC-Maxhöhen dienen als *unabhängige* Plausibilitätsprüfung. An Cu-Tagen sollten alle drei Größen (Modell, HBAS_SC, IGC-Max) konvergieren — IGC-Max liegt typisch 50–200 m unterhalb der tatsächlichen Wolkenbasis (Wolkenflugverbot).

7.3 Regionsinterne Streuung als doppeltes Signal

Die in Komponente B berechnete regionsinterne Streuung (siehe 4.3) wird zweifach genutzt:

- **Als Unsicherheitsmaß der Prognose:** Hohe Streuung der Basishöhe oder des Windes signalisiert dem Nutzer eine unsichere bzw. inhomogene Vorhersage für die Region.
- **Als Qualitätskriterium der Regionsdefinition:** Zeigt eine Region dauerhaft hohe HBAS_SC- oder Windrichtungs-Varianz, ist sie vermutlich zu groß oder schneidet eine echte Luftmassengrenze. Dies liefert ein automatisches Kriterium, welche Regionen in der nächsten Iteration gesplittet werden sollten.

Damit schließt sich der iterative Regionsschnitt aus Komponente A: Statt manuell zu raten, wo Regionen zu grob sind, liefert die saisonale Varianzstatistik einen datengetriebenen Hinweis. Konkret: Regionen nach mittlerer saisonaler HBAS_SC-Standardabweichung ranken, die obersten Kandidaten entlang topographischer Strukturen aufteilen.

7.4 Tuning-Strategie

- Initialisierung mit Liechtis Originalwerten.
- Validierungs-Saison (mindestens April–September, idealerweise 2 Jahre).
- Bias-Analyse pro Tageszeit, Tagesstärke, Region — wie Richter (2011).
- Parameter-Optimierung mit Grid-Search oder Bayesian Optimization (z.B. *scikit-optimize*). Bei 5–6 Parametern problemlos handhabbar.
- Regionale Stratifizierung: ΔT_0 vermutlich verschieden für Voralpen, Hauptkamm, Südseite — separate Fits prüfen.

7.5 Erfolgsmetriken

- RMSE der vorhergesagten Steigwerte vs. IGC-Median < 0.3 m/s
- RMSE der Basishöhe vs. HBAS_SC < 200 m
- Klassifikationsgüte Tagestypen (Cu/Blue/Gewitter) $> 85\%$ gegen IGC-Realität
- Saisonale Bias-Stabilität: kein Trend April–September

8. Datenverfügbarkeits-Asymmetrie (Querschnittsthema A ↔ E)

Ein verwertbares Tuning-Sample erfordert **gleichzeitig** am selben Tag und in derselben Region: (1) den passenden ICON-Lauf, (2) genug IGC-Flüge mit Thermiknutzung, (3) einen überhaupt fliegbaren Tag. Diese drei Bedingungen sind stark ungleich verteilt — das betrifft sowohl die Regionsdefinition (Komp. A) als auch das Tuning (Komp. E) und wird daher als Querschnittsthema behandelt.

8.1 Drei Asymmetrie-Achsen

- **Räumlich:** IGC-Dichte korreliert mit Fluggeländen, nicht mit meteorologischer Repräsentativität. Eine Region um einen aktiven Segelflughafen hat hunderte Flüge/Saison; eine gleich große Hochgebirgsregion ohne Startplatz null. Gerade die fein verfeinerten Level-9-Hochgebirgsregionen (wegen hoher Varianz gesplittet) sind oft die mit den wenigsten IGC-Daten.
- **Zeitlich:** Flüge gibt es nur an guten Tagen. Schwachthermik- und Blue-Days mit niedriger Basis sind im IGC-Sample systematisch unterrepräsentiert — aber genau dort macht das Modell die größten Fehler (vgl. Richters Überschätzung bei schwacher Thermik). Das am dringendsten benötigte Sample fehlt am ehesten.
- **Selektion:** Auch an fliegbaren Tagen fliegen Piloten die besten Linien zur besten Zeit; Tagesrandzeiten und schwächere Regionen sind unterrepräsentiert.

8.2 Konsequenzen fürs Setup

- **IGC-Dichte als 4. Kriterium der Regionsdefinition:** Eine nie validierbare Region ist für die Tuning-Phase wertlos. Verfeinerung auf Level 9 nur dort, wo auch genug IGC-Dichte existiert; sonst auf Level 8 belassen und per Parameter-Transfer versorgen.
- **Parameter-Transfer zwischen Regionen:** Parameter (ΔT_0 , Entrainment etc.) an datenreichen Regionen fitten, dann auf datenarme Regionen mit ähnlichem Charakter (Höhe, Exposition, Relieftyp) übertragen. Verbindet sich mit der regionalen Stratifizierung aus 7.4.
- **Mindest-Stichprobengröße als Gütefilter:** Pro (Region, Tag, 30-min-Bin) eine Mindestzahl Kreisflüge fordern, sonst ist der Median statistisch wertlos. Tage/Bins

darunter werden markiert und vom Tuning ausgeschlossen (nicht ignoriert).

- **Schnittmenge bestimmt die nutzbare Stichprobe:** Das effektive Tuning-Sample ist weder "alle ICON-Tage" noch "alle IGC-Flüge", sondern deren Schnittmenge unter den Gütefiltern — realistisch deutlich kleiner als zunächst gedacht.

Früh abschätzen: Vor dem Bau der vollen Pipeline lohnt eine grobe Abschätzung der nutzbaren Schnittmenge (IGC-Flüge je Region/Saison × fliegbare Tage mit ICON-Abdeckung). Das entscheidet, wie fein die Regionen für ein belastbares Tuning überhaupt sein dürfen, und ob die Pilotregion genug Signal liefert.

9. Datenhaltungs- und Archivierungsstrategie

Die beiden Validierungs-Datenquellen haben fundamental unterschiedliche Vergänglichkeit, woraus sich die zentrale Handlungsempfehlung ableitet: **sofort mit dem ICON-Mitschnitt beginnen, unabhängig vom Stand des Modellcodes.**

- **IGC-Daten sind quasi-permanent:** WeGlide/OLC halten Flüge über Jahre vor — rückwirkend jederzeit ziehbar, kein Zeitdruck.
- **ICON-Daten sind flüchtig:** Der DWD löscht nach ~2 Tagen. Jeder gute Thermiktag, der jetzt nicht als nativer GRIB2 mitgeschnitten wird, ist unwiederbringlich verloren — die IGC-Seite lässt sich nachholen, die ICON-Seite nicht.

9.1 Warum nicht rein selektiv nach IGC-Dichte archivieren

Nur die guten Flugtage mitzuschneiden würde genau den Schönwetter-Bias aus Abschnitt 8 einbauen: Schwachthermik- und Blue-Days — wo das Modell am meisten irrt und Validierung am dringendsten wäre — hätten dann keine ICON-Daten. Vollständig alles auf Modelllevel-Ebene zu archivieren ist andererseits teuer. Lösung: ein zweistufiges Archiv.

9.2 Zweistufiges Archiv

Mehrere Läufe sammeln, nicht nur den operationellen Anker. Für die Prognose (4.6) wird *ein* Lauf gewählt (03 UTC). Für Sammlung und Validierung gilt das Gegenteil: Hier soll der spätere Tuning-Vergleich gegen den *bestmöglichen* ICON-Input laufen, nicht gegen den zufällig früh verfügbaren. Der entscheidende Faktor ist die Vorlaufzeit zum Flugzeitpunkt — ein späterer Lauf hat mehr reale Morgenbeobachtungen assimiliert und trennt so ICONs NWP-Vorhersagefehler sauberer vom eigenen Modellfehler. Würde man nur gegen den 03-UTC-Lauf tunen, kompensieren die Parameter (ΔT_0 , Entrainment) teilweise ICONs Vorlaufzeit-Fehler und passen im operationellen Betrieb nicht.

Lauf	Für Validierung/Tuning	Für operationelle Prognose
00 UTC	Frühe Basis, lange Vorlaufzeit	Früheste Morgenprognose
03 UTC	Mittlere Vorlaufzeit	Anker (operationell)
06 UTC	Sweet Spot — kurze Vorlaufzeit, ganzer Flugtag abgedeckt	Vormittags-Update
09 UTC	Sehr aktuell, aber Vormittag/Onset teils vorbei	Mittags-Update / Trigger

Der 06-UTC-Lauf ist für die Validierung der Sweet Spot: deckt den kompletten Flugtag (~07–16 UTC) noch im Horizont ab, hat aber 3 h mehr Beobachtungen als der 03-UTC-Lauf. Der 09-UTC-Lauf ist noch aktueller, verliert aber Information über den frühen Onset.

Tier	Was	Läufe	Zweck
Tier 1 Forcing-Archiv	~15 Input-Variablen, Alpen-Bbox, schlank	00/03/06/09 UTC, täglich	Vermeidet Schönwetter-Bias; alle Tagestypen; alle Vorlaufzeiten
Tier 2 Voll-Archiv	Volle 3D-Profile, alle Modelllevel	06 UTC, an guten Tagen	Reserve für Modell-Erweiterungen / neue Variablen

Tier-2-Entscheidung: diagnostisch statt prädiktiv. Die DWD-Löschfrist (~2 Tage) läuft *pro Lauf ab dessen eigenem Init-Zeitpunkt* — der 06-UTC-Lauf lebt also bis ~06 UTC zwei Tage später. Das erlaubt eine bessere Logik als das prädiktive Raten am frühen Morgen: Die Entscheidung wird auf den 09-UTC-Lauf (verfügbar ~11:30 UTC) verschoben, der die einsetzende Konvektion mit nur ~2 h Vorlauf bereits "sieht" — also fast diagnostisch statt prognostisch. Bei positiver Entscheidung wird retroaktiv das Tier-2-Vollprofil des *06-UTC-Laufs* nachgeladen (liegt noch komfortabel im Löschfenster). Damit ist die Entscheidungsbasis (09 UTC, aktuell) von der archivierten Größe (06 UTC, beste Flugtag-Abdeckung) entkoppelt.

Erweiterbar: Zur Entscheidungszeit (Mittag) existieren bereits reale Beobachtungen des Tages (METAR/SYNOP der Bergstationen, Satelliten-Cu-Bedeckung), die noch belastbarer sind als jede Modelldiagnostik. Für den Start genügt der 09-UTC-ICON-Lauf als Trigger; die Beobachtungsdaten sind eine spätere Verbesserung.

9.3 Sofortmaßnahmen (auch ohne Modellcode)

Maschine: HomeServer als Primärsystem. Begründung: Speicher ist der härtere Constraint (das Archiv wächst monoton über Jahre, Platten sind nachrüstbar; ein VPS mit begrenztem Speicher erzwingt früh Daten-Akrobatik). Der Bandbreiten-Constraint des HomeServers ist weicher als er scheint: Tier 1 ist schlank (niedrige hunderte MB/Tag, läuft unbemerkt auch tagsüber), und der große Tier-2-Download lässt sich dank der 2-Tage-Frist problemlos in die Nacht verschieben. Voraussetzung: stabile Maschine und Internetverbindung.

Cronjobs (HomeServer):

Job	Zeit (UTC)	Zweck	Bandbreite
Tier-1-Sammlung	~06:30, 09:30, 12:30, 15:30	Je Lauf (00/03/06/09) schlank ziehen	gering, tagsüber ok
Tier-2-Trigger	~12:00	09-UTC-Lauf diagnostisch auswerten	minimal
Tier-2-Download	nachts, ~23:00	06-UTC-Vollprofile guter Tage nachladen	hoch, aber Freizeit

Der entscheidende Trick ist die **Entkopplung von Trigger (mittags, klein) und Download (nachts, groß)**: Mittags fällt nur die Entscheidung, der bandbreitenintensive Tier-2-Download läuft nachts in der freien Bandbreite. Die Lauf-Verfügbarkeitslatenz (~2,5–3 h nach Init, siehe 4.6) ist in den Job-Zeiten bereits berücksichtigt.

Weitere Sofortmaßnahmen:

- **Ablagestruktur** nach Datum/Lauf/Variable, idealerweise schon im Zielformat der Pipeline (Zarr), um spätere Konvertierung zu vermeiden.
- **Metadaten-Log:** pro Tag Lauf, Variablen und Tier-Stufe festhalten, um den Bestand jederzeit zu kennen.
- **Variablen großzügig wählen:** für den reinen Mitschnitt im Zweifel ein paar Variablen mehr — Speicher ist billiger als ein verlorener Thermiktag, wegwerfen einfacher als nachbeschaffen.

- **IGC parallel, ohne Eile:** kein WeGlide-Zugang nötig, um M0 zu starten. Die ICON-Seite ist die einzige zeitkritische Komponente; IGC-Flüge sind quasi-permanent und werden nachgeladen, sobald der API-Key vorliegt (monatlicher Batch genügt).

Reiner HomeServer-Weg ist hier ausreichend (stabile Maschine vorausgesetzt). Bei häufigeren Ausfällen oder längeren Abwesenheiten wäre ein Hybrid denkbar — ein VPS zieht fristgerecht 24/7 und parkt wenige Tage zwischen, der HomeServer synct nachts ins Langzeitarchiv. Da Maschine und Internet stabil sind, ist dieser Zusatzaufwand aktuell nicht nötig.

9.4 Format

Zarr ist dem reinen GRIB2-Stapel überlegen, sobald über viele Tage analysiert wird: chunked, paralleler Zugriff auf Zeitreihen einzelner Variablen/Regionen, ohne jedes GRIB-File einzeln zu öffnen (das Open-Climate-Fix-Archiv nutzt Zarr aus genau diesem Grund). Empfehlung: GRIB2 eingangsseitig als Rohformat behalten und täglich in ein wachsendes Zarr-Archiv anhängen.

10. Zeitplan und Meilensteine

Phase	Inhalt	Dauer	Meilenstein
M0	Archiv-Cronjobs (Kap. 9) — SOFORT	1-2 Tage	Tägl. ICON-Mitschnitt (00/03/06/09) + Tier-2-Trigger läuft
M1	Region & AHD (Komp. A)	2 Wo.	AHD-Profile für 20 Regionen
M2	ICON-Pipeline (Komp. B)	3 Wo.	Eine Region, eine Saison im Speicher
M3	Modellkern v0 (Komp. C)	5 Wo.	Reproduktion Liechti-Figs 3+4
M4	IGC-Pipeline (Komp. D)	4 Wo.	Validierungsdatensatz Saison 2025
M5	Erste End-to-End-Läufe	2 Wo.	Bias-Plots, erste Findings
M6	Parameter-Tuning (Komp. E)	4 Wo.	Kalibrierte Parameter pro Region
M7	Multi-Region-Skalierung	3 Wo.	Gesamter Alpenraum operationell
M8	Dokumentation & Publikation	2 Wo.	Reproduzierbare Pipeline

Gesamtdauer ca. 25 Wochen netto. Bei Teilzeit (z.B. 1 Tag/Woche) entsprechend länger. M1, M2 und M4 sind parallelisierbar. **M0 hat höchste Priorität und läuft unabhängig vom übrigen Fortschritt** — jeder ungesammelte gute Thermiktag ist als nativer ICON-GRIB2 unwiederbringlich verloren (siehe Kap. 9).

11. Risiken und offene Fragen

Risiko	Mitigation
Auflösungsgrenzen ICON-D2 in tiefen Tälern	Mehrere Stützpunkte pro Region, Mittelung; Korrekturfaktor pro Höhenklasse
IGC-Selektion: Piloten fliegen beste Bärte, nicht Mittel	Modell-Output als Q90 (statt mean) reporten; ggf. explizite Bart-Statistik
WeGlide-API: Firewall blockt Server-IPs; ToS untersagt exzessive Nutzung	API-Key proaktiv anfragen (löst IP-Block); aggressives Caching, höfliches Crawling; OLC als Fallback
HTOP_DC-Qualität für Blue Days nicht validiert	Initial-Check an klaren Strahlungstagen im Inntal
Talwind-/Konvergenzeffekte in Phase 1 nicht erfasst	Regtherm-Kopplung als Phase-2-Erweiterung dokumentiert (5.5); ICON-W und Windvarianz als Datengrundlage
Regionsschnitte ad hoc	Iteration: starten mit grobem Schnitt, verfeinern bei systematischen Biases

12. Anhang

12.1 Software-Stack (Vorschlag)

Python 3.11+, Stack vollständig open source:

- **Numerik:** numpy, scipy, xarray
- **Geodaten:** geopandas, rasterio, shapely, pyproj
- **Regionalisierung:** PySAL/spopt (max_p_regions, skater), HydroBASINS/EU-Hydro als Geometrie-Input, Alpenkonvention-Perimeter (bzw. Alpine Space) als physiographische Maske
- **NWP:** cfrib (eccodes-Backend), herbie (DWD-Loader)
- **IGC:** aerofiles oder eigener Parser; WeGlide-Python-Client (PyPI) für API-Zugriff
- **Optimierung:** scikit-optimize, optuna
- **Visualisierung:** matplotlib, plotly, folium für Karten
- **Speicher:** Zarr für das wachsende ICON-Zeitreihenarchiv (chunked, paralleler Zugriff), NetCDF für einzelne Modelldaten, Parquet für Flugaggregate

12.2 Referenzliteratur

- Liechti, O. & Neininger, B. (1994): ALPTHERM — A PC-based model for atmospheric convection over complex topography. Technical Soaring 18(3), 73–78.
- Liechti, O. (2002): Regtherm — Regional coupling of valley wind systems and sea breezes. OSTIV Publication.
- Richter-Trummer, D. (2011): Verifikation des Grenzschichtmodells ALPTHERM anhand Flugdaten. Bachelorarbeit, Universität Innsbruck.
- Hindman, E. et al. (2007): Verification of TopTask Competition. Technical Soaring.
- Whiteman, C.D. (1982): Breakup of temperature inversions in deep mountain valleys. J. Appl. Meteor. 21, 270–289.
- Whiteman, C.D. (2000): Mountain Meteorology — Fundamentals and Applications. Oxford University Press.
- Zardi, D. & Whiteman, C.D. (2013): Diurnal Mountain Wind Systems. In: Mountain Weather Research and Forecasting, Springer, 35–119.
- Lehner, B. & Grill, G. (2013): Global river hydrography and network routing — HydroSHEDS / HydroBASINS. Hydrol. Process. 27, 2171–2186.
- Duque, J.C. et al. (2012): The max-p-regions problem. J. Regional Science 52, 397–419. (Grundlage spatial regionalization / PySAL spopt)
- DWD ICON Database Reference, Numerical Weather Prediction (verfügbar auf opendata.dwd.de).

12.3 Verzeichnisstruktur (Vorschlag)

```
alptherm-icon/  
├── data/  
│   ├── dem/ # Copernicus DEM (statisch)  
│   ├── regions/ # GeoJSON-Polygone + AHD-NetCDFs  
│   ├── icon/ # ICON GRIB2 (Cache)  
│   ├── igc/ # IGC-Files (Cache)  
│   └── aggregates/ # Flugaggregate (Parquet)  
├── src/  
│   ├── regions/ # Komp. A  
│   ├── icon_pipeline/ # Komp. B  
│   ├── model/ # Komp. C – Modellkern  
│   ├── igc_pipeline/ # Komp. D  
│   └── validation/ # Komp. E  
├── notebooks/ # Explorative Analyse  
├── configs/ # Region-Definitionen, Parameter  
└── tests/
```

12.4 Historische ICON-Daten — Archiv-Optionen

Der DWD selbst bietet kein Langzeitarchiv (nur 2-Tage-Fenster). Für Stufe-3-Klimatologie und Rück-Validierung kommen drei externe Quellen infrage:

Quelle	Modell / Auflösung	Abdeckung	Eignung & Caveat
Open-Meteo Historical Forecast API	ICON-D2 / -EU, Punktabfrage (JSON)	ab ~2021	Pragmatischster Weg für Stufe 3. Keine Auth, CC-BY-4.0. Nicht für lange Zeitreihen (Modellversions-wechsel); für Varianzmuster über 1-2 Saisons unkritisch.
Open Climate Fix Zarr-Archiv (HuggingFace)	ICON-EU (7 km), volle Felder	ab März 2023	Näher an Rohdaten (ganze Felder statt Punkte). Nur EU-Auflösung — für grobe Varianzmuster (Föhn, Talwind-Heterogenität) ausreichend.
ERA5 Reanalyse	~25 km, lückenfrei	ab 1940	Zu grob für Talwinde; nur als Ergänzung für großräumige Luftmassengrenzen brauchbar.

Konsistenz-Caveat: Wird Stufe 3 auf Open-Meteo-Daten gerechnet, Komponente B aber später auf nativem DWD-GRIB2, muss die HBAS_SC-Definition identisch sein. Open-Meteo interpoliert/prozessiert teils nach — absolute Höhen können minimal abweichen. Für relative Varianzmuster irrelevant, aber Quelle dokumentieren, um später keine Scheinunterschiede zwischen Stufe-3-Klimatologie und operationellem Lauf zu interpretieren.

12.5 Nächster konkreter Schritt

Empfehlung: Mit Komponente A (Region & AHD) für eine einzelne Pilotregion starten — z.B. das Unterinntal/Steinberge-Gebiet, das auch Richter analysiert hat. Vorteile: vorhandene Referenzdaten, überschaubarer Scope, sofort testbare Geometrie. Parallel den ICON-Variablenkatalog (Komp. B) implementieren, zunächst für genau diesen Punkt. Erst nach erfolgreichem End-to-End-Test auf den ganzen Alpenraum skalieren.